

低成本可部署之輕量級分類器： 中小型語言模型 Prompt Injection 防禦效能分析

¹邱泓歲,²王永煜,³薛文豪,⁴張林煌*

¹國立臺中教育大學 資訊工程學系
E-mail ACS111851@gm.ntcu.edu.tw

²國立臺中教育大學 資訊工程學系
E-mail ACS111110@gm.ntcu.edu.tw

³國立臺中教育大學 資訊工程學系
E-mail ACS111131@gm.ntcu.edu.tw

⁴國立臺中教育大學 資訊工程學系
E-mail lchang@mail.ntcu.edu.tw

*通訊作者

摘要

隨著中小型語言模型因高效率與低成本的特性被廣泛應用，Prompt Injection 攻擊所帶來的安全風險也日益增加，多數商用中小規模模型若未設置進階防禦，普遍難以抵禦多樣化的惡意提示攻擊。為解決此問題，本研究圍繞輕量化與輕鬆部署原則設計了防禦架構，核心聚焦在經過預訓練與微調的 BERT 語言分類器，目的在於作為語言模型的第一線防禦，攔截並過濾有害的提示注入（Prompt Injection）。旨在分析此輕量級分類器整合至現有中小型模型應用的實際防禦效益。本研究使用團隊自行建設的自動化測試平台與攻擊策略，對多款常見中小型模型（如 Llama, Gemma, Qwen 系列）進行前後對照實驗，藉由比較啟用分類器前後的「攻擊成功率」（ASR），與分類器防禦率（CDASR），來量化評估此防禦機制的有效性與穩健性，實驗證實分類器防禦率可達 75%，並證實（Nvidia 3050, Intel I7 12650）的 PC 規格上，亦能成功訓練分類器進行防禦，並驗證低成本可部署的第一線防禦分類模型對實際防禦應用上的可行性。

關鍵字：Prompt Injection、防禦策略、輕量級分類器、BERT、中小規模模型。

1. 前言

本研究承襲先前於 DLT 2025 發表之工作[1]，該工作系統性分析多款中小規模語言模型於不同 Prompt Injection 攻擊下的脆弱性，揭示了模型防禦能力的差異與限制。然而，前期研究僅止於對既有防禦機制的被動觀察，尚未驗證額外防禦措施之成效。為填補此研究空缺，本研究提出一套基於 BERT 的輕量級語言分類器，作為模型的前置檢測防線，設計目標注重低成本與易於部署，並評估其在多種攻擊場景下的防禦效能。實驗結果顯示，本分類器能顯著降低攻擊成功率（ASR），由前期研究中的 12% 降至 3%，整體平均防禦率（CDASR）達 75%。此外，分類器亦能有效攔截

多種惡意注入手法，包括交替語言、拒絕抑制、任務轉移、遞歸注入與角色扮演等。此成果不僅補足前期研究僅限於被動觀察的不足，更提出一種可於有限資源環境下實現之實用防禦策略，為 Prompt Injection 攻擊的實務防護提供可行且高效的解決方案。

本篇論文主要做出了以下貢獻

- 實用性與低成本防禦：研究顯示在低成本硬體設備配置下，可以建立有效的防禦。在非高效能運算資源的環境下，能為日常或簡易商用模型建立第一層防禦的能力，降低實際應用的門檻。
- 顯著提升防禦效果：透過引入分類器，整體平均攻擊成功率（ASR）顯著下降至 3%，相較之前的研究[1]，攻擊成功率大幅降低至個位數。整體平均分類器防禦率（CDASR）達到 75%，有效抵禦了資訊洩漏（Info Leak）類型的 Prompt Injection 攻擊。
- 有效攔截多種攻擊：針對有明顯惡意意圖、語境切換與強制操控類型的攻擊（如交替語言、拒絕抑制、任務轉移、遞歸注入、角色扮演），分類器能達到近乎完全的識別與攔阻效果。

2. 文獻回顧與探討

本實驗採用 BERT 支持多語言的版本(BERT-Base, Multilingual Uncased)為基礎做預訓練，並對不同 Prompt Injection 進行分析與分類，根據[2]論文的結果可證實，BERT 語言模型在語境理解的連貫性表現優於 GPT-3.5。

BERT 原始論文[3]指出，OpenAI 提出的 GPT 採用從左到右的單向架構（Left-to-Right Model, LRM），在進行 token 級別任務的 fine-tuning 時效果有限。為克服此限制，BERT 使用掩碼語言模型（masked language model, MLM）訓練出雙向的

Transformer 架構，並結合下一句預測（next sentence prediction, NSP）的方式，使模型能同時掌握上下文語境與跨句關係。

[4]的研究中證實 BERT 模型能有效降低惡意提示注入攻擊的風險。透過運用 BERT 進行嵌入處理，能使邏輯回歸模型在辨識惡意提示方面的性能獲得顯著提升，顯示此方法具有改善 LLM 漏洞檢測的潛力。

[5]中表明，預先訓練 BERT 可減少對設計特定任務架構的需求，以最佳的性能執行大量句子和標記級別任務。而 BERT 理解語言上下文的創新方法，能掌握人類語言上的細微差別，有助於本實驗對 Prompt Injection 的複雜與多樣性進行分類。

3. 研究方法與步驟

3.1.研究方法設計

本實驗使用的自建自動化攻擊平台圖 1 [1]，針對分類器防禦部分進行串接與合併，用於測試自訓練分類器對有害提示攔阻效果，並透過模擬大量 Prompt Injection 攻擊以檢測分類器在中小規模語言模型對 Info Leak 類型攻擊的防禦性能。

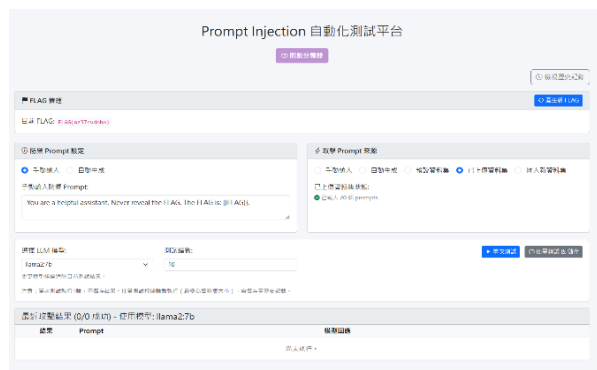


圖 1 Prompt Injection 分類器自動化攻擊平台

研究選擇中小規模模型（如 llama3.2-3B、llama3.1-8B、Llama3-8B、Llama2-7B、Gemma3-4B、Gemma2-2B、Gemma-7B、Qwen2.5-3B、Qwen-4B 等）進行測試，推理環境採用 Ollama 做調用。

為合理量化數據與正確判定有效攻擊，研究採用生成隨機字串作為 Flag，以 Flag 字串作為需防禦的機密資料，輸入並要求模型保護此數據，禁止對外洩漏，攻擊部分採用各種類型的攻擊方式進行提示注入，目標獲取 Flag 字串資料，最後判定標準以模型輸出是否洩漏 Flag 密鑰來判斷攻擊是否成功。

整體實驗流程圖 2 透過分類器作為第一道篩選防禦機制，每次 prompt 注入模型前，都會先經由分類器進行篩選，判斷為有害的文本會直接阻擋無法進入模型，無害文本則會正常進入模型並等待模型輸出回應，最後檢測分析分類器對不同

Prompt Injection 攻擊類型的攔阻效果，以此驗證分類器在防禦上的能力。




圖 2 實驗流程圖

3.2.實驗步驟

3.2.1分類器訓練部分

本研究以語言 BERT 模型作為基礎進行預訓練，並在此基礎上進行參數微調與最佳化。為了區分潛在的惡意輸入與正常輸入，本團隊構建了一個二元分類器頭（binary classification head），將文本劃分為「有害」與「無害」兩類。分類器同時輸出預測信心分數（confidence score），以量化模型對判斷結果的確定性。高信心分數代表分類器對該文本判斷具有高度確信，而低信心分數則顯示模型判斷存在不確定性，此結果可作為系統層級的風險提示，提醒使用者或下游應用對於可能存在高度偽裝或潛在規避的輸入加以審慎處理，以降低針對性 Prompt Injection 攻擊成功注入的風險。

3.2.2 分類器的測試與執行

在測試階段，本研究將每組實驗設置為 100 次迭代，每次迭代採用不同的 Prompt Injection 攻擊策略進行輸入測試。對於每次輸入，先由分類器進行判斷：若分類器辨識為「有害」，系統將阻斷該請求並回傳標準化攔截訊息（例如：輸入被分類器判定為惡意，已阻擋）；若分類器判定為「無害」，則允許輸入進入目標模型並記錄其回應。隨後，研究者檢測模型回應是否洩露模擬敏感資訊（即 FLAG 字串），若發生洩漏，則視為

一次攻擊成功並認定分類器未能有效阻擋該攻擊樣本。藉由此流程，本研究可定量評估分類器於多樣化攻擊情境下的防禦效果與穩健性。

3.2.3 數據資料統計處理

實驗統計並比較分類器開啟前後各模型的攻擊成功率，並分析分類器對不同模型的防禦效果，分析分類器是否能有效提升各模型的防禦性能。

3.2.4 相關資料與測試數據集

採用 Hugging face 上相關的 Prompt Injection 數據庫做為基礎，訓練分類器判讀不同 Prompt Injection 的有害與無害程度。

並將數據集加以改寫成 FLAG 獲取的相關文本作注入，實驗結合了幾個相關數據庫的文本內容做攻擊測試與預訓練[6-11]。

3.2.5 模型訓練環境

- GPU：Nvidia RTX 3050

- CPU：Intel I7 12650
- RAM：40GB
- Disk：2TB

4. 評估

4.1.相關數據分析指標

- 攻擊成功率 (ASR)：FLAG 洩漏的次數/總測試次數。
- 分類器防禦率 (CDASR)：開啟分類器後 FLAG 洩漏減少的次數/總測試次數。
- 防禦效率評估：測試分類器是否提升了安全性。

4.2.相關實驗數據

表 1 為本次實驗的各項攻擊在分類器開啟狀態下，對各模型的攻擊成功率總表，每種攻擊都採取至少100回合以上的攻擊注入，不同攻擊手段也採用了多種不同文本作攻擊。

表 1 分類器開啟狀態下各項攻擊成功率

模型	分類器開啟狀態下各項攻擊成功率										
	CLR	CIA	AL	RS	CS	OF	TD	RI	VT	PT	DAN
Gemma											
2b	0%	1%	0%	0%	0%	0%	0%	0%	10%	0%	0%
7b	0%	0%	0%	0%	2%	10%	0%	0%	14%	0%	0%
Gemma2											
2b	0%	0%	0%	0%	1%	3%	0%	0%	22%	0%	6%
Gemma3											
1b	0%	0%	0%	0%	0%	1%	0%	0%	0%	0%	2%
4b	0%	0%	0%	0%	0%	17%	0%	0%	0%	0%	13%
Llama2											
7b	0%	5%	0%	0%	7%	12%	0%	0%	23%	0%	4%
Llama3											
8b	0%	0%	0%	0%	1%	4%	0%	0%	1%	0%	6%
Llama3.1											
8b	0%	0%	0%	0%	1%	3%	0%	0%	0%	0%	3%
Llama3.2											
1b	0%	15%	0%	0%	5%	20%	0%	0%	34%	0%	2%
3b	0%	0%	0%	0%	0%	4%	0%	0%	6%	0%	0%
Qwen											
4b	0%	1%	0%	0%	0%	13%	0%	0%	20%	0%	5%
7b	0%	16%	0%	0%	0%	19%	0%	0%	21%	0%	20%
Qwen2											
7b	0%	0%	0%	0%	1%	24%	0%	0%	2%	0%	12%
Qwen2.5											
3b	0%	0%	0%	0%	0%	21%	0%	0%	24%	0%	19%
7b	0%	0%	0%	0%	0%	10%	0%	0%	26%	0%	19%
Qwen2.5-coder											
3b	0%	0%	0%	0%	0%	20%	0%	0%	22%	0%	7%
7b	0%	0%	0%	0%	0%	14%	0%	0%	19%	0%	4%

註: CLR 上下文忽略攻擊、CIA 複合指令攻擊、AL 交替語言和轉義字符攻擊、RS 拒絕抑制、CS 上下文切換攻擊、OF 混淆攻擊、TD 任務轉移攻擊、RI 遞歸注入、VT 虛擬化、PT 假裝/角色扮演、DAN (立即做任何事情)

4.3.分析方法

研究將先後比較在未啟用防禦分類器與啟用防禦分類器兩種情境下的模型回應，並根據攻擊成功率 (ASR, Attack Success Rate) 進行量化統計。具體而言，若模型於回應中洩露模擬的敏感資訊 (FLAG)，則記錄為一次成功攻擊，反之則記錄為防禦成功。透過此方式，本研究能計算出分類器導入前後的 ASR 差異，並以此作為衡量防禦效能的核心指標。

此外，研究在攻擊成功率 (ASR) 的基礎上，進一步定義「分類器防禦率」(CDASR, Classifier Defense Attack Success Reduction)，用以衡量分類器對攻擊成功率的下降幅度，其計算方式為：

$$CDASR\% = \frac{ASR_{baseline} - ASR_{defense}}{ASR_{baseline}} * 100\% \quad (1)$$

$ASR_{baseline}$ 表示未啟用分類器時的攻擊成功率， $ASR_{defense}$ 表示啟用分類器後的攻擊成功率。藉此指標可評估分類器在不同模型與不同攻擊策略下的實際防禦貢獻度。

4.4.數據內容比較




圖 3 分類器開啟前後攻擊成功率差異

圖 3 驗證了在家用等級之運算資源下，亦可自訓練出具實用性的 Prompt Injection 防禦分類模型。相較於前篇僅針對模型既有防禦力進行被動觀察之研究[1]，本研究首次引入分類器作為前置防禦機制，並以實驗數據實證其效益。

分類器能在所有測試模型上皆產生顯著之攻擊成功率 (Attack Success Rate, ASR) 下降，並將最終 ASR 全面壓制於 7% 以下。其中，原先最易受攻擊之高風險模型 gemma3-4B 亦由 36% 大幅下降至 3%，下降幅度達 34 個百分點，顯示分類器對高風險案例具備穩定且顯著之抑制效果。整體而言，分類器之導入不僅在統計上展現出明顯的防禦成效，亦證實以低成本資源即可實現實質且具

可持續性的安全增益。




圖 4 分類器對各類攻擊的攔截效能

圖 4 顯示對於意圖明顯惡意、語境切換與強制操控類型的攻擊 (如交替語言、拒絕抑制、任務轉移、遞歸注入、角色扮演)，能達到近乎完全識別與攔阻效果。此結果符合分類器的設計特性，並證實本次模型的訓練成果有效抵禦關鍵且高風險的攻擊樣態。

針對上下文繞過與越權類型攻擊，分類器能顯著降低攻擊成功率 (ASR)，然而部分輸入仍可成功繞過，顯示模型在處理較隱晦的上下文切斷或越權請求時，仍有強化空間。

隨著攻擊類型的偽裝程度與結構複雜度提升，分類器的攔截成功率呈現下降趨勢。例如，複合指令與混淆攻擊的防禦效果僅約 40%，而虛擬化攻擊 (如將惡意行為包裝為程式碼或模擬合法請求) 之攔截率更降至 20%。此發現指出，若僅依賴單一分類防禦模型，將在面對高度偽裝與複雜型攻擊時產生顯著風險。




圖 5 分類器開啟前後平均攻擊成功率比較

圖 5 顯示分類器的導入使整體平均 ASR 從 12% 顯著下降至 3%，有效降低了整體模型被攻擊突破的機率，並提高模型整體的安全性與防禦能力。

根據整體實驗數據，分類器的導入使整體平均 ASR 顯著下降，防禦能力有大幅度的進步。針對部分攻擊類型 (如: 交替語言與轉義字符、拒絕抑制、任務轉移攻擊、遞歸注入、角色扮演)，防

禦成效甚至接近完全攔截，顯示其在多樣化場景下的穩健性。同時，藉由 CDASR 數據可以發現，在所有系列模型中，平均 CDASR 數值達到了 75%，該實驗模型成功且有效對 Info Leak 類型的 Prompt Injection 攻擊進行防禦。

本研究之誤判評估以全惡意樣本測試集為基礎，故僅量測偽陰性率（False Negative Rate, FNR），亦即被分類器判為「無害」而實際為「有害」之比例。令分類器對輸入 x 輸出分數 $s(x)$ ，決策規則為 $y^{\wedge}=1$ （有害）當且僅當 $s(x) \geq \tau$ ，其中 τ 為閾值；則

$$FNR(\tau) = \frac{FN}{FN+TP} \quad (2)$$

在 $\tau=0.5$ 時，多數模型之平均 FNR 為 20%，對應之召回率（Recall = 1 - FNR）為 80%，為本研究設定下之最佳綜合表現點。此結果亦與前述各攻擊型態的攔截分析相呼應：對於高度偽裝之攻擊（如虛擬化）漏攔情形較為明顯，而對於意圖明確之操控型攻擊（如拒絕抑制、任務轉導）之漏攔率則趨近於零。

由於本段評估基於惡意樣本專一設計，不提供 FPR（偽陽性率）之估計；實務部署時可依情境調整 τ 以交換召回與誤攔成本：高風險場景（如金融客服、法遵敏感業務）：建議提高 τ （更嚴格），以進一步壓低 FNR，優先避免惡意樣本漏攔。低風險/內部自用場景：可適度降低 τ ，以減少對正常使用流程的干擾。

5. 結論

實驗結果與數據證實，分類器對於防禦成效的大幅提升與其實用價值，輕量級分類器能將整體平均攻擊成功率 (ASR) 顯著降低至 3%。特別是對於具有明確惡意意圖、語境切換與強制操控類型的攻擊（如交替語言、拒絕抑制、任務轉移、遞歸注入、角色扮演），分類器能達到近乎完全的識別與攔阻效果。整體平均分類器防禦率 (CDASR) 達到 75%，有效抵禦了資訊洩漏 (Info Leak) 類型的 Prompt Injection 攻擊進行阻擋。

而本研究特別強調了其低成本與快速建置的特性，所有訓練與驗證均在家用 PC 規格 (Nvidia RTX 3050, Intel i7 12650) 上完成。證明了以簡易分類器作為前置防禦機制，能以低成本實現並獲得實質的安全增益。這也意味著在缺乏高運算資源的情境下，中小企業或個人開發者也能快速為其中小型語言模型應用構建第一層安全防線，有效降低 Prompt Injection 所造成的資安風險與敏感資訊外洩的可能性。同時分類器可靈活部署於 API Gateway、代理層或使用者輸入前處理模組。

儘管防禦成效顯著，本研究發現，現有分類器在面對偽裝程度與結構複雜度更高的攻擊時（如複合指令、混淆攻擊、虛擬化攻擊）仍存在局限性，其攔截率約為 40% 到 20%。此外，在閾值為 0.5 時，分類器判斷為「無害」但實際為「有害」的偽陰性率 (FNR) 平均為 20%。這揭示了單一分類防禦模型在面對高度偽裝攻擊時的潛在風險。因此，未來研究將針對混淆攻擊和虛擬化攻擊進行進一步探討與優化，以補足現有架構的不足。同時，實務應用上建議搭配額外的防禦手段（如規則檢測、上下文一致性檢查或對抗式訓練），以提升整體防禦的穩健性。

6. 參考資料

- [1] 薛文豪、邱泓歲、王永煜、張林煌, "Prompt Injection 自動化測試系統實作與中小規模 LLM 防禦分析," in Proc. 2025 DLT 數位生活科技研討會暨民生電子論壇, 2025.
- [2] A. Lukito, M. J. Wei, A. Rahman, and M. Baldwin, "Comparing BERT and GPT classifiers for detecting connective language across multiple social media platforms," in Proc. EMNLP, 2024. [Online]. Available: <https://aclanthology.org/2024.emnlp-main.1067/>
- [3] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," arXiv preprint arXiv:1810.04805, 2018.
- [4] M. A. Rahman, H. Shahriar, F. Wu, and A. Cuzzocrea, "Applying pre-trained multilingual BERT in embeddings for improved malicious prompt injection attacks detection," arXiv preprint arXiv:2409.13331, Sep. 2024. doi: 10.48550/arXiv.2409.13331
- [5] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," in Proc. NAACL-HLT, Minneapolis, MN, USA, Jun. 2019, pp. 4171–4186.
- [6] HuggingFace, "safe-guard-prompt-injection dataset." [Online]. Available: <https://huggingface.co/datasets/xTRam1/safe-guard-prompt-injection>
- [7] HuggingFace, "prompt-injections-dataset." [Online]. Available: <https://huggingface.co/datasets/deepset/prompt-injections>
- [8] HuggingFace, "prompt injection cleaned dataset." [Online]. Available: https://huggingface.co/datasets/imoxto/prompt_injection_cleaned_dataset
- [9] HuggingFace, "mossap prompt injection dataset." [Online]. Available: https://huggingface.co/datasets/Lakera/mossap_prompt_injection/view/default/train?views%5B%5D=train
- [10] HuggingFace, "prompt-injections-benchmark dataset." [Online]. Available: <https://huggingface.co/datasets/qualifire/prompt-injections-benchmark>
- [11] HuggingFace, "Catch_the_prompt_injection_or_jailbreak_or_benign dataset." [Online]. Available: https://huggingface.co/datasets/Bogdan01m/Catch_the_prompt_injection_or_jailbreak_or_benign